1. Задания для выполнения

1.1. Исследование набора данных

1. Отдельно для каждого из наборов данных (ФКГ, модуль позиционирования) получить имена столбцов, определяющих названия параметров. Для набора ФКГ изучить все 3 представленных файла. В описание к ответу вывести имена столбцов, которые содержат названия классов, отнесение к которым и будет являться задачей классификации.
2. По каждому из наборов в описании результата указать количество категориальных и числовых параметров.
3. Удалить из открытых наборов данных столбцы, не относящиеся к значимым параметрам и наименованию классов.
4. При необходимости, для каждого из наборов перевести категориальные данные в числовые. В обязательном порядке проверить наименования целевых классов и провести необходимые преобразования.
5. По каждому из наборов вывести соотношения классов в текстовом виде в формате: «Класс 1»: N записей/паттернов.
6. Для каждого из наборов вывести в виде столбчатой диаграммы данные о количестве уникальных классов (ось X - имя класса, ось Y - количество классов в наборе).
7. Для набора ФКГ объединить все представленные файлы. На выходе должен получиться один DataFrame. Этот DataFrame сделать в виде отдельной переменной.
8. Для набора ФКГ сформировать графики, на которых будут показаны (по отдельности) представленные классы в виде волновой формы, огибающей и энергии непрерывного вейвлетного преобразования. По оси X отложить значения, соответствующие порядковом номеру отсчетов. При желании можно сформировать эти значения в виде секунд, минут, отталкиваясь от значения частоты дискретизации данных, равного 1 кГц.
9. Информация от скольки инерциальных-измерительных сенсоров хранится в наборе данных от модуля позиционирования? Описание набора представлено ниже.

10. Для каждого из классов набора от модуля позиционирования выведите графики от одного или нескольких датчиков с формированием легенды. По оси X отложить значения, соответствующие порядковому номеру отсчетов.
11. Для наборов данных сформируйте два DataFrame с именами x_(наименование набора) и y_(наименование набора). y - DataFrame с именами классов для каждой из представленных записей, x - DataFrame со значениями параметров этих записей. Учтите что для для набора ФКГ будет сформировано 4 набора таких DataFrame. Поэтому проследите, чтобы их имена не повторялись.
12. Сформируйте отдельные DataFrame, включающие в себя нормализованные данные со значениями.
13. Выведите на графики нормализованные значения для отдельных классов с сформированной легендой и подписями к осям. При этом учтите что в наборе для модуля позиционирования данные представлены для нескольких сенсоров сразу! Выведите на график показания по трем осям для одного из них. Для набора ФКГ выведите на один график значения для одного из классов во всем трем параметрам (волновое представление, огибающая, энергия непрерывного вейвлетного преобразования)/

1.2. Работа с моделями машинного обучения Scikit-learn

1. При помощи библиотеки Scikit-learn создайте модели машинного обучения (дефолтные параметры):
    - Random Forest;
    - Support Vector Machine;
    - Decision Tree;
    - Stochastic Gradient Boosting;
    - k-nearest Neighbors;
    - Gradient Boosting.
2. Подключите и создайте модель машинного обучения Catboost с дефолтными параметрами.
3. При помощи библиотеки Scikit-learn разделите каждый из сформированных ранее наборов данных на тестовые и тренировочные.

4. Примените созданные модели машинного обучения к тестовому и тренировочному наборам. Для каждой из моделей выведите ее конечную точность.
5. Реализуйте k-fold механизм кросс-валидации для каждой из созданных моделей машинного обучения.
6. По результатам работы для каждого из наборов отберите 3 модели машинного обучения, показавшие наилучший результат классификации. Выбор каждой модели обоснуйте письменно в виде комментариев.
7. Произведите поиск значений параметров для отобранных моделей на тестовом и тренировочном наборах, которые позволят повысить их точность. Нужно произвести работу для каждого из наборов и для подобранных для них моделей. В виде комментариев приведите набор наилучших параметров для моделей с выводом об их точности.
8. Проведите поиск наилучших параметров моделей с использованием механизма кросс-валидации.
9. Для 3х моделей, показавших наилучшие значения по метрике accuracy рассчитайте значения метрик precision, recall, f1-score. Какая из метрик больше подойдет для оценки точности работы моделей с набором фонокардиограмм и набором от модуля позиционирования?
10. Постройте кривую ROC-AUC для отобранных моделей машинного обучения и в комментариях приведите описание полученных результатов.

2. Оформление ответа на задания

При выполнении заданий в Jupiter notebook, Google collaboratory или Kaggle необходимо при последовательном выполнении в виде markdown указывать текст задания и ответ на него. Если ответ подразумевает вывод под исполняемой ячейкой то нужно явно прописать в ее первой строке ***«ответ на задание «текст задания»: »***. Учитывайте что код в ячейках выполняется последовательно и при изменении вышестоящих ячеек необходим их перезапуск.

При выполнении заданий в среде PyCharm необходимо будет приложить исходные коды программы и отчет в текстовом виде, сопровождаемый графическими материалами. По сути должен получиться отчет о проделанной работе по каждому из пунктов.

Функции, которые нужно и можно использовать приведены в презентациях к занятиям, которые были ранее и расположены в системе moodle - https://lms.tsu.ru/mod/folder/view.php?id=813736. При необходимости нужно обращаться к документации или соответствующим топикам - https://letmegooglethat.com/

Обязательно учтите при выполнении что полученные результаты Вы будете использовать при выполнении последующих блоков лабораторной работы. Поэтому уже на этом этапе продумывайте архитектуру кода таким образом, чтобы в дальнейшем уже не повторять его.

Результаты работы по завершению всех блоков (включая работу с моделями машинного обучения из пакета Scikit-learn) нужно будет отправить в системе moodle как ответ на соответствующее задание.

3. Описание наборов данных

3.1. Набор фонокардиограмм

Фонокардиограмма (ФКГ) - запись звуковых колебаний, возникающих в результате работы сердца.

Набор (https://lms.tsu.ru/mod/folder/view.php?id=813748, ***«Набор Фонокардиограммы.zip»***) включает в себя участки ФКГ плода, полученные при их регистрации с поверхности тела беременной. Частота дискретизации составляет 1 кГц, все данные подвергались предварительной обработке. Как видно из рисунка 3.1 с поверхности тела беременной была зарегистрирована ФКГ, при прослушивании которой различимы только материнские сердцебиения. Однако, в результате ее обработки были выделены сердцебиения плода, маскируемые деятельностью сердца матери. В части случаев такого результата не удается добиться и на результирующей фонокардиограмме присутствуют паттерны, соответствующие материнским тонам. Эти тоны могут как перекрывать отдельные тоны сердца плода, так и располагаться между ними и/или постепенно замещая в зависимости от частоты сердечных сокращений плода и матери.

В состав аннотированного датасета вошли 36 ФКГ от женщин на разных сроках беременности, разного возраста, конституции и состоянием плода. Всего на них было выделено 13186 паттернов. Часть ФКГ характеризуется высоким уровнем шумов, который не снижается даже при проведении предварительной обработки.

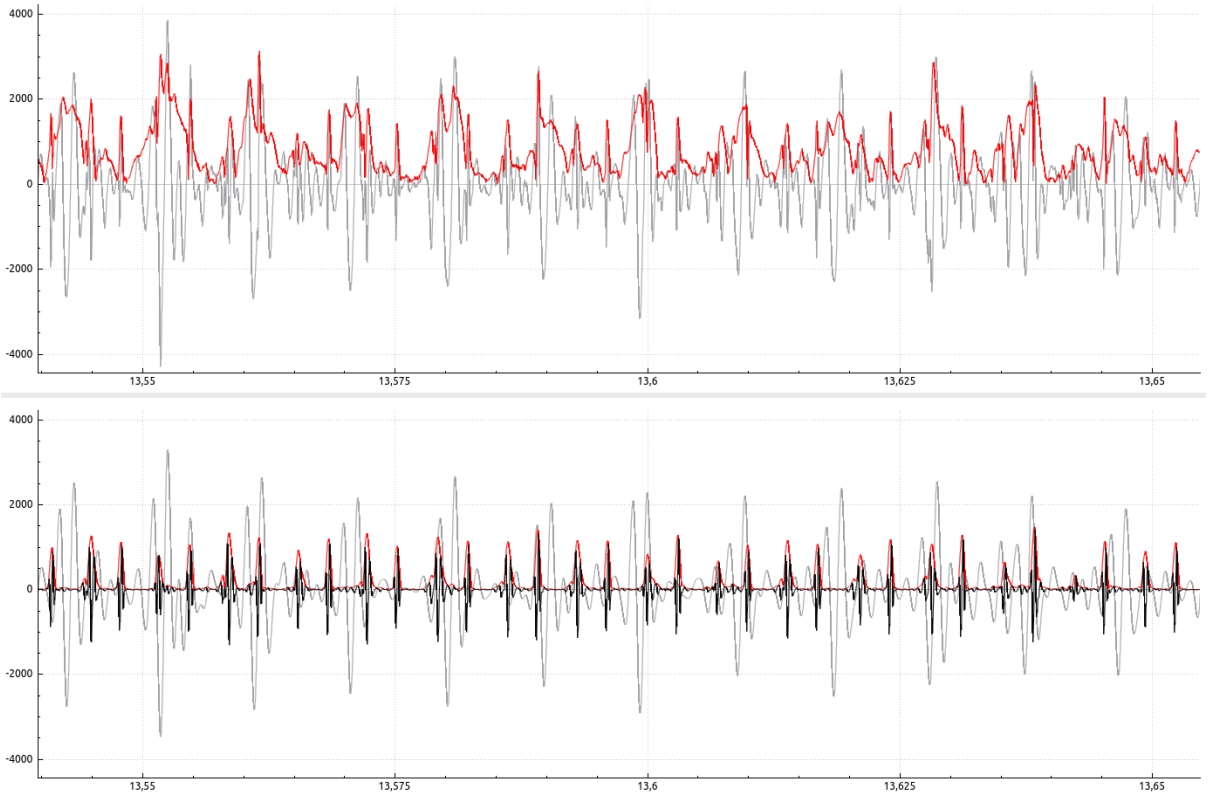
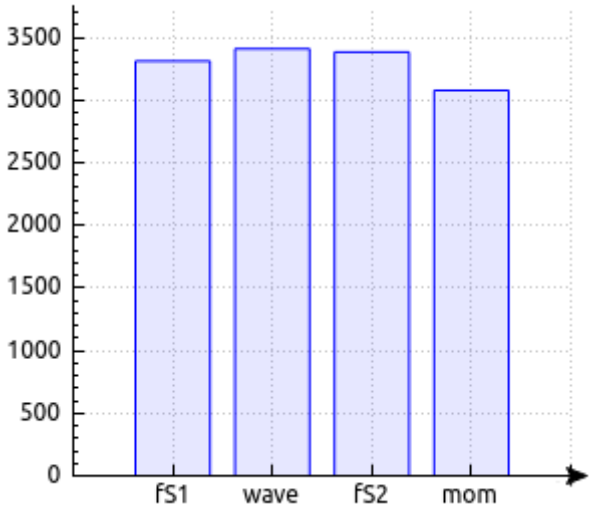


Рисунок 3.1 - иллюстрация результата обработки ФКГ.
Верхний график - амплитудное представление исходной ФКГ с огибающей Гилберта. Нижний график: черный цвет - результат предварительной обработки; серый цвет - амплитудное представление в частотном диапазоне ниже полезного - выраженное материнское сердцебиение; кривая, описывающая результат предварительной обработки - огибающая по Гилберту.

Интерес представляют такие классы как (рисунок 3.2):

1. первый тон сердца плода. Используется для построения КИГ - кривых, отражающих частоту сердечных сокращений и используемых для оценки состояния сердечно-сосудистой системы.
2. второй тон сердца плода. Используется для построения КИГ.

3. шумы. Визуально очень похожи на тоны сердца плода и матери. Часть шумов может пропускаться при работе с пороговыми фильтрами (в т.ч. с использованием разных огибающих и схожих методов).
4. тон сердца матери. Остаточные явления, которые обычно присутствуют в диапазоне частот ниже диапазона, характерного для тонов сердца плода. Однако, в ряде случаев проявляется и в целевом частотном диапазоне.



fS1 - первый тон сердца плода (3312 областей); fS2 - второй тон сердца плода (3383 области); wave - шумы (3410 областей); mom - тоны сердца матери (3081 область)

Рисунок 3.2 - Количественный состав областей на ФКГ, отнесенных к классам

Для выделенных на ФКГ паттернов, отнесенных к определенным классам, было осуществлено формирование набора csv-файлов, каждый из которых содержит значения отдельных признаков, используемых в дальнейшем для решения задачи классификации выделенных паттернов:

1. Волновое представление участков ФКГ (wave)
2. Значения огибающей по Гилберту (envelope)
3. Значения спектра непрерывного вейвлетного преобразования участка ФКГ (wes).

Численные значения признаков в этих файлах представлены в столбцах, имеющих названия, начинающихся с первой буквы признака в формате (для волнового представления): w_0, w_1, .., w_N.

3.2. Набор с модуля позиционирования

Представляет собой набор данных (***разделитель*** = ***‘,’***) от инерциальных измерительных систем, объединенных в модуль позиционирования роботизированной системы для восстановления утраченной функции конечности (https://lms.tsu.ru/mod/folder/view.php?id=813748, ***«Система позиционирования.csv»***). На сегодняшний день это информация о различных типах схватов кисти человека. Данные представляют собой ускорение в м/с по трем плоскостям, схематичное представление которые показано на рисунке 3.3.

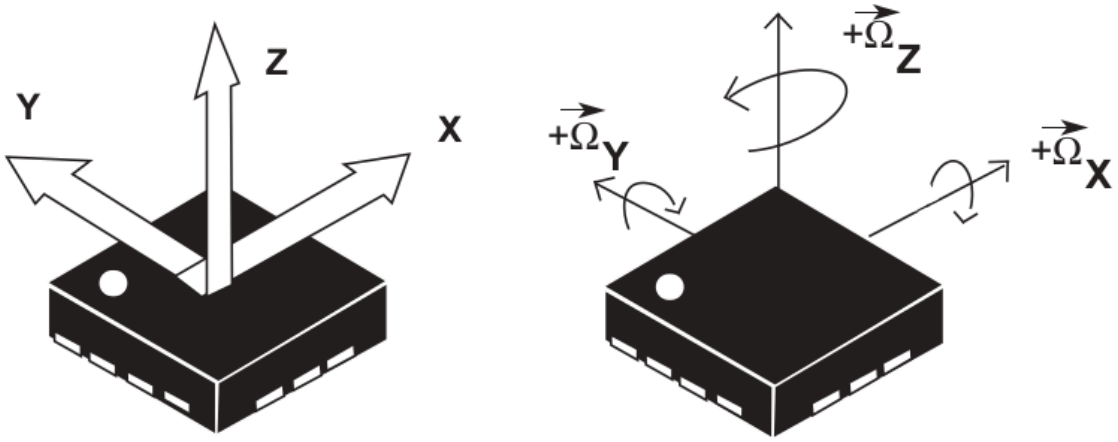


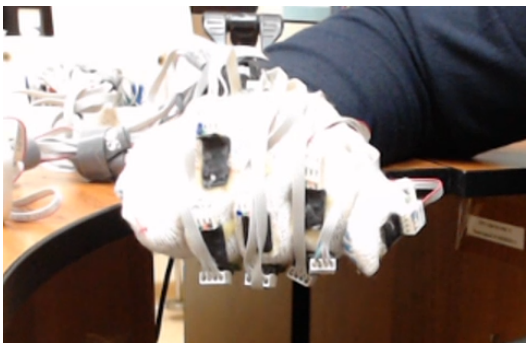
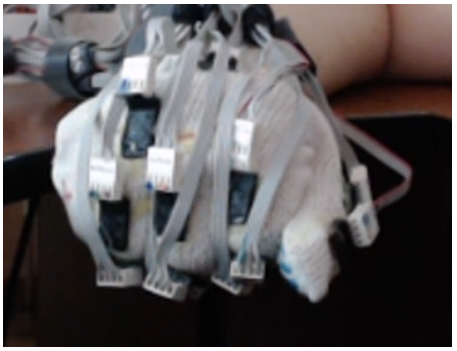
Рисунок 3.3 - направления осей вращения инерциальных-измерительных систем

Набор представляет собой файл формата csv, в строках которого расположены значения ускорений по осям в порядка: Датчик 1[ось x, ось y, ось z], Датчик 2[ось x, ось y, ось z], .., Датчик N[ось x, ось y, ось z]. При этом количество значения для каждой из осей составляет 104 отсчета. Это соответствует частоте дискретизации 104 Гц. Наименования классов, представленных в наборе располагаются в столбце «class_type». Описание классов представлено ниже:

Схват 0. Расслабленная рука




Схват 1. Кулак

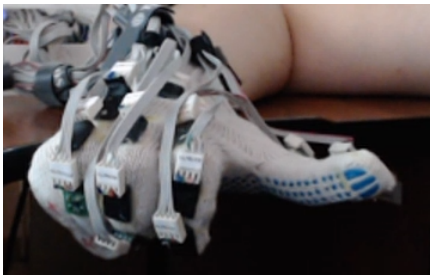
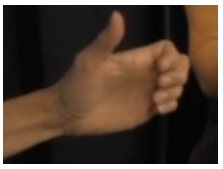


Схват 2. Прямая рука






Схват 3. Отведение большого пальца

Схват 4. Щипковый схват



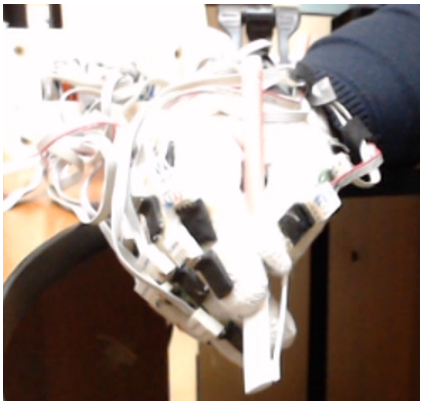


Схват 5. Удержание карточки





Схват 6. Удержание ручки





Схват 7. Удержание цилиндра





Схват 8. Удержание мячика



